

Superstore Profitability & Customer Retention Analysis (Personal Project)

Dataset:

- Data Volume: 9,900+ retail transaction records.
- Period: 4 years of historical data (2014 - 2017).
- Attributes:
 - Financials: Sales, Profit, Discount, and Shipping Cost.
 - Products: 3 Categories (Furniture, Office Supplies, Technology) and 17 Sub-categories.
 - Customers: Individual, Corporate, and Home Office segments.

Tech Stack : Excel, Googlesheets, SQL(BeekeeperStudio), Power BI



Executive Summary

The problem : จากการ EDA ข้อมูลนี้ธุรกิจมียอดขายสูงขึ้น แต่กำไรผันผวนและบางส่วนติดลบ รวมถึงไม่มีความชัดเจนว่าใครคือลูกค้ากลุ่มสำคัญ

The Approach: โหลดข้อมูลเข้า Excel ทำความเข้าใจ Dataset จากนั้นแปลงข้อมูลเป็น database โดยใช้ python และจากนั้นใช้ SQL ทำความสะอาดข้อมูลและสร้าง RFM Model แบ่งกลุ่มลูกค้า จากนั้นสร้าง Dashboard ใน Power BI เพื่อหาจุดที่ทำให้ขาดทุน

Result: พบลูกค้า At-Risk 149 รายที่สร้างรายได้สูง และพบว่าสินค้ากลุ่ม Tables/Bookcases คือสินค้าหลักในการขาดทุนโดยมีส่วนลดที่เยอะ

Methodology & Data Preparation

Data Cleaning: ด้วยปกติ dataset นี้ไม่มี missing values หรือข้อมูลมั่วแต่ถ้ามีการซ้ำซ้อนของข้อมูลจัดการกับปัญหา Split Line Items (ออเดอร์ซ้ำซ้อน) โดยใช้ SQL ในการทำ เราต้องเช็คว่าที่ออเดอร์มันซ้ำคือมันซ้ำทั้งหมดเลยไหมทั้งราคาสินค้าจำนวนสินค้าแต่จากที่เช็คไม่ซ้ำกันเกิดจากลูกค้าสั่งสินค้าตัวเดิมเพิ่มหรืออาจจะสั่งคนละรอบ

RFM Model

Logic: Recency(ลูกค้าซื้อครั้งสุดท้ายเมื่อไหร่), Frequency(ลูกค้าซื้อบ่อยแค่ไหน), Monetary(ยอดใช้จ่ายรวมเป็นเท่าไหร่)

Technique: ลูกค้าทั้งหมดมี 793คนเราใช้ฟังก์ชัน NTILE(4) หรือง่ายๆคือการแบ่งลูกค้าเป็น4กลุ่มเพื่อให้คะแนน 1-4 จาก Logic RFM Recencyยิ่งตัวเลขน้อยยิ่งดีใน Logic นี้ปกติฟังก์ชันมันให้คะแนนจากบนลงล่างซึ่ง recency คือตัวเลขยิ่งน้อยยิ่งดีเพราะฉะนั้นผมจึงได้ทำการเรียงจากมากไปน้อยเพื่อที่จะได้ให้คะแนนคนที่ recency น้อยได้คะแนนเต็ม4และคนที่มีย่อยให้เป็น1,2,3 ตามลำดับ และ frequency และ Monetary ตัวเลขยิ่งมากยิ่งดีเพราะฉะนั้นในการทำผมจึงเรียงจากน้อยไปมากตามปกติซึ่งคะแนนก็จะเรียงจาก1-4ตามน้อยไปมากเลย

Outcome: นำรหัสคะแนนมา concatenation (เช่น 444, 144) มาจัดกลุ่มลูกค้าออกเป็น 6 Segments(เช่น Champions, At-Risk, Hibernation)

	customer_id	customer_name	recency_days	frequency	monetary_value	r_score	f_score	m_score	rfm_str	total_score
1	SC-20380	Shahid Collister	31	9	5992.53	4	4	4	444	12
2	AD-10180	Alan Dominguez	30	8	6106.88	4	4	4	444	12
3	KM-16720	Kunst Miller	29	8	4909.47	4	4	4	444	12
4	ES-14080	Erin Smith	29	9	4657.93	4	4	4	444	12
5	BB-11545	Brenda Bowman	29	9	6765.73	4	4	4	444	12

Out come ตรงส่วนนี้อาจจะยังไม่เข้าใจจากนั้นผมจึงทำการแบ่งกลุ่มโดย code ดังนี้
Code:

```
CREATE TABLE customer_segment_final AS
SELECT customer_id, customer_name, recency_days, frequency,
monetary_value, r_score, f_score, m_score, rfm_str,
CASE
WHEN (r_score ≥ 4 AND f_score ≥ 4) THEN 'Champions'
WHEN (r_score ≥ 3 AND f_score ≥ 3) THEN 'Loyal Customers'
WHEN (r_score ≥ 4 AND f_score ≤ 2) THEN 'New Customers'
WHEN (r_score ≤ 2 AND f_score ≥ 3) THEN 'At Risk'
WHEN (r_score ≤ 2 AND f_score ≤ 2) THEN 'Hibernation'
ELSE 'Potential Loyalist' END AS customer_segment
```

FROM customer_segmentation;

อธิบายคือ

Champions: ถ้า score recency มากกว่าหรือเท่ากับ 4 และ frequency มากกว่าหรือเท่ากับ 4 เราจะยกให้เป็นลูกค้าประเภท Champions

Loyal Customers: ถ้า score recency มากกว่าหรือเท่ากับ 3 และ frequency มากกว่าหรือเท่ากับ 3 เราจะยกให้เป็นลูกค้าประเภท Loyal Customers

New Customers: ถ้า score recency มากกว่าหรือเท่ากับ 4 และ frequency น้อยกว่าหรือเท่ากับ 2 เราจะยกให้เป็นลูกค้าประเภท New Customers

At Risk: ถ้า score recency น้อยกว่าหรือเท่ากับ 2 และ frequency มากกว่าหรือเท่ากับ 3 เราจะยกให้เป็นลูกค้าประเภท At Risk

Hibernation: ถ้า score recency น้อยกว่าหรือเท่ากับ 2 และ frequency น้อยกว่าหรือเท่ากับ 2 เราจะยกให้เป็นลูกค้าประเภท Hibernation

Potential Loyalist: และถ้าคะแนนไม่ตรงกับเงื่อนไขด้านบนเลย (คำสั่ง ELSE) เราจะยกให้เป็นลูกค้าประเภท Potential Loyalist

1. **Champions (VIP):** ช้อปบ่อย ชื้อหนัก และเพิ่งซื้อ (คะแนน 4-5)
2. **Loyal Customers:** ช้อปบ่อยมาก แต่ความสดใหม่ (Recency) อาจจะลดลงบ้าง
3. **Potential Loyalist:** เพิ่งมาเป็นลูกค้าใหม่ แต่มีแววดี
4. **At Risk:** เคยช้อปบ่อยมาก แต่หายหน้าไปนานแล้ว (ต้องรีบดึงกลับมา!)
5. **Hibernating (Lost):** ชื้อน้อย และหายไปนานแล้ว
6. **New Customer:** ลูกค้ามาใหม่

จากนั้นเช็คผลลัพธ์

Code

```
SELECT
```

```
    customer_segment,
```

```
    COUNT(*) as total_customers,
```

```
    SUM(monetary_value) as total_sales,
```

```
    ROUND(AVG(monetary_value),2) as avg_spend_per_user
```


```
FROM customer_segment_final
```

```
GROUP BY customer_segment
```

```
ORDER BY total_sales DESC;
```

	customer_segment ▲	total_customers ▲	total_sales ▲	avg_spend_per_user ▲
1	Loyal Customers	179	673359.24	3761.78
2	At Risk	149	600042.98	4027.13
3	Hibernation	248	438117.01	1766.6
4	Champions	68	302323.4	4445.93
5	Potential Loyalist	82	175183.36	2136.38
6	New Customers	67	108175.08	1614.55

Strategic Dashboard



Zone A: (สุขภาพธุรกิจ): ดูแนวโน้มยอดขายเทียบกับกำไรโดยใช้แผนภูมิผสม (แกนคู่)

Zone B: (กลยุทธ์ลูกค้า): วิเคราะห์สัดส่วนกลุ่มลูกค้า


Zone C: (ความสามารถในการทำกำไรของผลิตภัณฑ์): ชีว่่าสินค้าที่มีกำไรและขาดทุนสูงสุด

ถ้าอยากลองดู interactive Dashboard


URL: https://github.com/lovedeveloperart/Superstore-Customer-Segmentation-Sales-Analysis/blob/main/Superstore_profitability_retention.pbix

จากนั้นกด View Raw ครับ

Insight 1 - Customer Retention 🧑




Insight: จากกลุ่ม Hibernation และ At Risk จะเห็นว่าลูกค้ากลุ่มนี้มีปริมาณที่เยอะมากและน่าสนใจตรงที่กลุ่ม At Risk ซึ่งมียอดซื้อสูงถึง \$600K เลยซึ่งมากที่สุดเกือบเทียบเท่ากับกลุ่มของลูกค้า Loyal Customer ถ้าหากเราดึง 20 % ของกลุ่ม At Risk กลับมาได้จะเพิ่ม revenue ประมาณ \$120K ต่อปี(อ้างอิงจาก Average Spend) ของกลุ่มของ Hibernation กลุ่มนี้เป็นลูกค้ากลุ่มที่ใหญ่สุดถึงแม้จะมียอดซื้อที่น้อยแต่เป็นกลุ่มที่น่าสนใจตรงถ้าเราดึงพวกเขากลับมาซื้ออาจจะทำให้เราเพิ่มรายได้ตรงนี้มากขึ้นด้วย เพราะฉะนั้นเราควรดึงลูกค้า 2 กลุ่มนี้กลับมาไม่จันอาจจะเสียรายได้



Key Finding

- At Risk = 149 customers
- Total Sales = \$600K
- Avg Spend สูงกว่า Loyal Customers
- ถ้า recover 20% → +\$120K revenue

Insight 2 - Profit Leakage (สินค้าที่ทำให้ขาดทุน)



Insight: สินค้าที่ทำให้ขาดทุนมากที่สุดคือ Tables, Bookcases ซึ่งจะเห็นจากกราฟว่าช่วง Q4 2014 - Q1 2015 ขาดทุนเยอะมากซึ่งสินค้า 2 ตัวนี้คือสินค้าที่ขาดทุนมากที่สุด

Key Finding

- Tables และ Bookcases มี Total Profit ติดลบสูงสุดในหมวด Furniture
- ช่วง Q4 2014 - Q1 2015 มี profit dip ชัดเจน
- สินค้าทั้ง 2 ตัวมีระดับ discount สูงผิดปกติเมื่อเทียบกับสินค้าอื่น discount ของ table อยู่ที่ประมาณ 26.13% และ bookcases ที่ประมาณ 21.11%

	sub_category ^	avg_discount_percent ^	total_profit ^
1	Binders	37.25	30221.64
2	Machines	30.61	3384.73
3	Tables	26.13	-17725.59
4	Bookcases	21.11	-3472.56

Business Recommendation 💰

- ส่วนลดของหมวดที่ขาดทุน
 - Action: ลดเพดานของส่วนลดในหมวดของสินค้าที่ขาดทุนให้ $\leq 15\%$ ในหมวดหมู่ที่มี Tables, Bookcases
 - Why: จากกราฟเห็นว่าสินค้าทั้ง2อย่างนี้มีตัวเลขกำไรติดลบยิ่งขายเยอะยิ่งขาดทุนทำให้ Profit margin รวมลดลงในช่วงปลายปี
- จัด **campaign** เพื่อดึงลูกค้ากลับมา
 - Action: อาจจะมีการจัดส่วนลดมุ่งเฉพาะกลุ่มนั้นๆที่เสี่ยงต่อการสูญเสีย retention เพื่อดึงลูกค้ากลุ่มนั้นกลับมาโดยเฉพาะกลุ่มของ **At Risk** และ **Herbination**
 - Why: ข้อมูลจากกราฟ customer segmentation พบว่ากลุ่ม At Risk มีขนาดกลุ่มที่ใหญ่และยอดการซื้อที่สูงมากๆถ้าดึงกลับมาได้อาจจะเพิ่มยอดขายตรงส่วนนี้ได้
- ทำระบบ **Member**
 - Action: ทำระบบสะสมคะแนนเมื่อซื้อสินค้ายอดเท่านี้จะได้แต้มเท่านี้เช่นซื้อยอด100บาทจะได้แต้ม50แต้มประมาณนี้
 - Why: เพื่อดึงลูกค้าใหม่มาให้ซื้อซ้ำเช่นถ้าเรามีโปรโมชั่นซื้อคู่ก็จะมีส่วนลดหรือเอาแต้มแลกเป็นส่วนลดก็จะสามารถดึงดูดให้เขามาซื้อเราซ้ำได้